



Université Sultan Moulay Slimane

École Nationale des Sciences Appliquées, Béni Mellal

MANUEL DES TRAVAUX PRATIQUES

Module : IA Appliquée à l'Industrie 4.0

Cycle d'Ingénieur : TDI S4

Responsable pédagogique

Pr. Hamid OUANAN

E-mail : h.ouanan@usms.ma

Année universitaire : 2025/2026

Projet fil rouge du manuel : Analyse des facteurs influençant le risque de maladies cardiaques

Cadre intégrateur du manuel – articulation entre le TP1, le TP2 et le TP3

Ce projet constitue le fil conducteur de l'ensemble du manuel. Le TP1 sert à décrire les variables une à une, le TP2 à étudier les relations entre variables, et le TP3 à vérifier statistiquement les constats observés avant de formuler une conclusion finale argumentée.

1. Contexte du projet

L'objectif de ce projet est d'analyser les facteurs influençant le risque de maladies cardiaques chez les patients. Pour mener cette étude, vous utiliserez le **Heart Disease Dataset (Cleveland)**, qui regroupe plusieurs variables relatives aux caractéristiques cliniques des patients.

2. Variables du jeu de données

Le tableau suivant présente les principales variables utilisées dans le projet. La variable cible **target** indique la présence ou l'absence de maladie cardiaque.

Variable	Description
age	Âge du patient.
sex	Sexe du patient (1 = homme, 0 = femme).
cp	Type de douleur thoracique (4 catégories).
trestbps	Pression artérielle au repos (en mm Hg).
chol	Taux de cholestérol sérique (mg/dl).
fbs	Glycémie à jeun > 120 mg/dl (1 = vrai ; 0 = faux).
restecg	Résultats de l'électrocardiogramme au repos (0, 1, 2).
thalach	Fréquence cardiaque maximale atteinte.
exang	Angine induite par l'exercice (1 = oui ; 0 = non).
oldpeak	Dépression ST induite par l'exercice par rapport au repos.
slope	Pente du segment ST lors de l'exercice (3 valeurs).
ca	Nombre de vaisseaux principaux colorés par fluoroscopie (0-3).
thal	Résultat de l'examen sanguin (3 = normal, 6 = fixe, 7 = réversible).
target	Variable cible indiquant la présence (1) ou l'absence (0) de maladie cardiaque.

3. Ce que chaque TP vous aide à construire

- Réaliser une analyse univariée des principales variables quantitatives et qualitatives du dataset.
- Étudier des relations bivariées pertinentes entre les variables du jeu de données, en choisissant des visualisations adaptées.
- Appliquer des tests statistiques appropriés pour vérifier certaines hypothèses sur les relations observées.
- Identifier les facteurs qui semblent les plus influents dans le risque de maladie cardiaque.
- Rédiger une conclusion claire, argumentée et rigoureuse à partir des résultats obtenus.

4. Livrables attendus

- Un notebook Python complet, exécuté et bien commenté.
- Un rapport synthétique présentant les principales analyses, visualisations et interprétations.
- Une conclusion finale mettant en évidence les variables les plus liées au risque de maladie cardiaque.

5. Consigne générale

Le projet doit être rédigé avec soin, en justifiant les choix méthodologiques et en distinguant clairement les constats descriptifs, les associations observées et les conclusions statistiques. Toute interprétation doit rester prudente et fondée sur les résultats obtenus.

TP1 : Analyse univariée pour le projet fil rouge

Support de travaux pratiques en Python – première étape du projet intégrateur

Contexte : Dans ce projet, vous intervenez en tant que data scientist dans le domaine de la santé. Votre objectif est de mieux comprendre le profil des patients et d’explorer les variables du jeu de données afin de préparer de futures analyses prédictives du risque de maladies cardiaques.

Problématique : Comment les caractéristiques démographiques et cliniques des patient(e)s influencent-elles le risque de développer une maladie cardiaque ?

1. Objectifs pédagogiques

- Charger un dataset dans un environnement Python.
- Identifier les variables numériques et catégorielles.
- Réaliser une analyse univariée quantitative et qualitative.
- Produire et interpréter des graphiques adaptés.
- Automatiser une partie de l’analyse à l’aide de fonctions Python.

2. Pré-requis et environnement de travail

- Connaissances de base en Python : variables, listes, fonctions, DataFrame.
- Bibliothèques utilisées : pandas, seaborn, matplotlib, scipy.
- Fichier de données attendu : **Base_Maladie_Cardiaque.csv**.

3. Rattachement au projet fil rouge

Le contexte, la problématique et le dictionnaire des variables sont présentés au début du manuel dans la section « Projet fil rouge ». Dans ce TP, on mobilise le même dataset pour apprendre à décrire chaque variable séparément avant d’étudier les relations entre elles dans les TP suivants.

4. Partie A – Chargement et préparation des données

4.1 Importation des bibliothèques et lecture du fichier

Commencez par importer les bibliothèques nécessaires, puis chargez le fichier CSV dans un DataFrame.

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from scipy import stats

df = pd.read_csv("Base_Maladie_Cardiaque.csv")
df.head()
```

Travail demandé :

- Exécuter le code précédent.
- Afficher les cinq premières lignes du DataFrame.

- Identifier les noms des colonnes.
- Préciser le nombre de lignes et de colonnes du dataset.

4.2 Transformation de certaines variables en type catégoriel

Certaines variables codées par des nombres représentent en réalité des catégories. Il est donc pertinent de les convertir en type category avant l'analyse.

```
# Transformation de quelques variables
df['sex'] = df['sex'].astype('category')
df['cp'] = df['cp'].astype('category')
df['fbs'] = df['fbs'].astype('category')
```

Rappel : Une fonction lambda est une fonction anonyme écrite sur une seule ligne. Elle est utile lorsqu'une transformation simple doit être appliquée rapidement.

```
double = lambda x: x * 2
print(double(5))
```

```
liste_variable = ["sex", "cp", "fbs", "restecg", "exang", "slope", "thal", "target"]
df[liste_variable] = df[liste_variable].apply(lambda x: x.astype("category"))
df.dtypes
```

Questions :

- Pourquoi sex, cp ou target ne doivent-ils pas être considérés comme des variables quantitatives continues ?
- Quel est l'intérêt pratique de convertir ces variables en type category ?
- Quelle différence faites-vous entre type Python et nature statistique d'une variable ?

5. Partie B – Analyse univariée d'une variable quantitative

Dans cette partie, on étudie principalement la variable **age**.

5.1 Rappels sur les indicateurs numériques

Indicateur	Ce qu'il mesure
Moyenne	Tendance centrale de la variable.
Médiane	Valeur qui partage la série en deux parties égales.
Mode	Valeur la plus fréquente.
Écart-type	Niveau de dispersion autour de la moyenne.
Variance	Dispersion au carré.
Minimum / Maximum	Valeurs extrêmes observées.
Q1 / Q3	Quartiles qui délimitent le cœur de la distribution.

IQR	Écart interquartile : $Q3 - Q1$.
Skewness	Mesure de l'asymétrie.
Kurtosis	Mesure de l'aplatissement ou du poids des queues.

5.2 Calcul automatique avec describe()

```
df['age'].describe()
```

5.3 Calcul détaillé des indicateurs

```
from scipy.stats import skew, kurtosis

age = df['age']
moyenne = age.mean()
mediane = age.median()
mode = age.mode()[0]
ecart_type = age.std()
variance = age.var()
min_age = age.min()
max_age = age.max()
q1 = age.quantile(0.25)
q3 = age.quantile(0.75)
iqr = q3 - q1
asymetrie = skew(age)
aplatissement = kurtosis(age)
```

Aide à l'interprétation : Pour une distribution normale, la skewness est proche de 0. Une skewness positive indique généralement une queue vers la droite. La kurtosis est souvent interprétée par comparaison avec une loi normale.

Travail demandé :

- Compléter un tableau récapitulatif des indicateurs de la variable age.
- Comparer moyenne et médiane. La distribution semble-t-elle symétrique ?
- Déduire, à partir de Q1, Q3 et IQR, si la dispersion centrale est forte ou modérée.

5.4 Visualisation graphique de la variable age

Graphique	Utilité
Histogramme	Observer la forme générale de la distribution.
Boxplot	Repérer médiane, quartiles et valeurs aberrantes.
Courbe de densité (KDE)	Observer une version lissée de la distribution.
Violin plot	Combiner densité et résumé statistique.
QQ Plot	Comparer la distribution observée à une loi normale.

Histogramme

```
plt.figure(figsize=(10, 6))
sns.histplot(df['age'], bins=20, kde=False, color='blue')
plt.title("Histogramme de l'âge des patients")
plt.xlabel("Âge")
plt.ylabel("Fréquence")
plt.show()
```

Boxplot

```
plt.figure(figsize=(8, 6))
sns.boxplot(x=df['age'], color='lightblue')
plt.title("Boxplot de l'âge des patients")
plt.xlabel("Âge")
plt.show()
```

Courbe de densité

```
plt.figure(figsize=(10, 6))
sns.kdeplot(df['age'], fill=True, color='green')
plt.title("Courbe de densité de l'âge des patients")
plt.xlabel("Âge")
plt.ylabel("Densité")
plt.show()
```

Violin plot

```
plt.figure(figsize=(8, 6))
sns.violinplot(x=df['age'], color='lightcoral')
plt.title("Violin plot de l'âge des patients")
plt.xlabel("Âge")
plt.show()
```

QQ Plot

```
plt.figure(figsize=(8, 6))
stats.probplot(df['age'], dist="norm", plot=plt)
plt.title("QQ Plot de l'âge des patients")
plt.xlabel("Quantiles théoriques")
plt.ylabel("Quantiles observés")
plt.show()
```

Questions d'analyse :

- Que montre l'histogramme sur la répartition des âges ?
- Le boxplot met-il en évidence des valeurs aberrantes ?
- Le QQ plot confirme-t-il une distribution proche de la normale ? Justifier.
- Quel graphique trouvez-vous le plus facile à interpréter pour un public non spécialiste ?

6. Partie C – Analyse univariée d'une variable qualitative

On étudie ici la variable **sex**, qui est une variable catégorielle.

6.1 Résumé numérique

Grandeur	Interprétation
Fréquence absolue	Nombre d'observations par catégorie.
Proportion	Part relative de chaque catégorie.
Mode	Catégorie la plus fréquente.

```
variable = df['sex']
frequence_absolue = variable.value_counts()
proportion = variable.value_counts(normalize=True) * 100
mode = variable.mode()[0]
```

```
tableau_qualitative = pd.DataFrame({
    'Catégorie': frequence_absolue.index,
    'Fréquence absolue': frequence_absolue.values,
    'Proportion (%)': proportion.values,
    'Mode': [mode] + [''] * (len(frequence_absolue) - 1)
})

tableau_qualitative
```

Travail demandé :

- Donner la fréquence absolue de chaque catégorie.
- Donner la proportion correspondante en pourcentage.
- Identifier la catégorie dominante.

6.2 Représentations graphiques

Diagramme en barres

```
plt.figure(figsize=(8, 6))
sns.countplot(x='sex', data=df, palette='Set2')
plt.title("Diagramme en barres du sexe des patients")
plt.xlabel("Sexe (1 = Homme, 0 = Femme)")
plt.ylabel("Nombre de patients")
plt.show()
```

Barres avec proportions

```
proportions = df['sex'].value_counts(normalize=True) * 100
plt.figure(figsize=(8, 6))
ax = sns.barplot(x=proportions.index, y=proportions.values, palette='Set2')
ax.bar_label(ax.containers[0], fmt='%1.1f%%', padding=3)
plt.title("Proportions du sexe des patients")
plt.xlabel("Sexe (1 = Homme, 0 = Femme)")
plt.ylabel("Proportion (%)")
plt.show()
```

Diagramme circulaire

```
plt.figure(figsize=(8, 6))
df['sex'].value_counts().plot.pie(autopct='%1.1f%%', labels=['Homme', 'Femme'], startangle=90)
plt.title("Diagramme circulaire du sexe des patients")
plt.ylabel('')
plt.show()
```

Donut chart

```
plt.figure(figsize=(8, 6))
values = df['sex'].value_counts()
plt.pie(values, labels=['Homme', 'Femme'], autopct='%1.1f%%', startangle=90,
        wedgeprops={'width': 0.3})
plt.title("Donut chart du sexe des patients")
plt.show()
```

Questions d'analyse :

- Quelle catégorie est la plus représentée ?
- Quel graphique est le plus lisible pour comparer les fréquences ?
- Dans quel cas un pie chart est-il moins recommandé qu'un bar plot ?

7. Partie D – Automatisation de l'analyse

L'objectif est maintenant d'éviter de répéter manuellement les mêmes calculs pour chaque variable quantitative.

7.1 Récupération automatique des variables quantitatives

```
liste_variable_quanti = df.select_dtypes(include=['number']).columns.tolist()
liste_variable_quanti
```

7.2 Fonction de statistiques descriptives

```
def statDesc(base):
    liste_variable_quanti = base.select_dtypes(include=['number']).columns.tolist()
    nb_obs = base[liste_variable_quanti].count()
    moyenne = base[liste_variable_quanti].mean()
    max_ = base[liste_variable_quanti].max()
    min_ = base[liste_variable_quanti].min()
    std = base[liste_variable_quanti].std()
    var = base[liste_variable_quanti].var()
    q1 = base[liste_variable_quanti].quantile(0.25)
    q2 = base[liste_variable_quanti].quantile(0.50)
    q3 = base[liste_variable_quanti].quantile(0.75)
    return pd.DataFrame({
        "Nb_obs": nb_obs, "Moyenne": moyenne, "Max": max_, "Min": min_,
        "std": std, "var": var, "Q1": q1, "Q2": q2, "Q3": q3
    })

statDesc(df)
```

7.3 Fonction de génération automatique des graphiques

```
def graphique_quanti(base):
    liste_variable_quanti = base.select_dtypes(include=['number']).columns.tolist()
    for i in liste_variable_quanti:
        sns.histplot(base[i], bins=30, color="lightblue"); plt.show()
        sns.boxplot(base[i], color="lightgreen"); plt.show()
        sns.kdeplot(base[i], color="blue", fill=True); plt.show()
        sns.violinplot(base[i]); plt.show()
        stats.probplot(base[i], dist="norm", plot=plt); plt.show()
```

7.4 Fonction finale

```
def statDescFinal(base):
    graphique_quanti(base)
    result = statDesc(base)
    return result

statDescFinal(df)
```

Travail demandé :

- Tester les trois fonctions sur le dataset.
- Vérifier que toutes les variables quantitatives sont bien prises en compte.
- Proposer une amélioration personnelle de la fonction statDesc ou graphique_quanti.

8. Travail à rendre

- Le notebook Python complété et exécuté.
- Un court compte rendu (1 à 2 pages) contenant les principales observations.
- Une interprétation personnelle des résultats obtenus pour au moins une variable quantitative et une variable qualitative.
- Une proposition d'amélioration ou d'extension du code d'automatisation.

Conseil méthodologique : Après avoir identifié les types de variables avec **df.dtypes**, comparez toujours le type informatique avec la nature statistique réelle de la variable. Cette vérification évite de nombreuses erreurs en EDA.

9. Extension facultative

- Adapter le même travail à une autre variable quantitative que age.
- Adapter l'analyse qualitative à une autre variable catégorielle comme cp ou target.
- Créer une fonction d'automatisation pour les variables qualitatives.
- Ajouter une détection automatique simple des valeurs aberrantes à partir de l'IQR.

TP2 : Analyse bivariable pour le projet fil rouge

Support de travaux pratiques en Python – deuxième étape du projet intégrateur

Contexte : Dans ce TP, vous allez prolonger l'analyse exploratoire du même jeu de données afin d'identifier les relations entre les variables. L'objectif est de comprendre comment deux variables évoluent ensemble et comment interpréter ces relations dans une démarche de data science.

Problématique : Quelles relations peut-on mettre en évidence entre les caractéristiques démographiques et cliniques des patient(e)s, et comment ces relations peuvent-elles orienter l'analyse prédictive d'une maladie cardiaque ?

1. Objectifs pédagogiques

- Distinguer les trois grandes formes d'analyse bivariable : quanti-quanti, quali-quali et quanti-quali.
- Réaliser des visualisations adaptées pour étudier une relation entre deux variables.
- Calculer et interpréter une corrélation linéaire simple.
- Construire et lire un tableau croisé pour deux variables qualitatives.
- Comparer une variable quantitative selon des groupes définis par une variable qualitative.

2. Pré-requis et environnement de travail

- Avoir réalisé le TP1 sur l'analyse univariée ou maîtriser les bases de pandas, seaborn et matplotlib.
- Fichier de données attendu : **Base_Maladie_Cardiaque.csv**.
- Bibliothèques principales : pandas, seaborn, matplotlib, numpy et plotly (facultatif).

3. Variables utiles pour cette étape du projet

Dans ce TP, nous travaillerons principalement sur quelques variables représentatives du dataset : age, trestbps, chol, thalach, sex et cp. Elles permettent d'illustrer les trois cas classiques d'analyse bivariable.

Variable	Rôle dans le TP
Age	Âge du patient.
Trestbps	Pression artérielle au repos.
Chol	Taux de cholestérol sérique.
Thalach	Fréquence cardiaque maximale atteinte.
Sex	Sexe du patient.
Cp	Type de douleur thoracique.

4. Partie A – Analyse bivariée quanti-quanti

L'analyse quanti-quanti étudie la relation entre deux variables quantitatives. Dans ce TP, nous allons observer la relation entre l'âge, la pression artérielle, le cholestérol et la fréquence cardiaque maximale.

4.1 Importation des bibliothèques et chargement du jeu de données

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np

df = pd.read_csv("Base_Maladie_Cardique.csv")
df.head()
```

Travail demandé :

- Exécuter le code précédent et vérifier que le fichier est bien chargé.
- Afficher les cinq premières lignes du DataFrame.
- Repérer les variables quantitatives qui seront utilisées dans cette partie.

4.2 Analyse graphique : scatter plot

Le scatter plot permet de représenter chaque observation par un point. Il est particulièrement utile pour voir si deux variables semblent évoluer ensemble, s'il existe une tendance générale, ou si certaines observations sont atypiques.

```
sns.scatterplot(x='age', y='trestbps', data=df)
plt.title("Relation entre l'âge et la pression artérielle au repos")
plt.show()
```

4.3 Analyse graphique : pairplot

Le pairplot offre une vue d'ensemble des relations possibles entre plusieurs variables quantitatives. Il permet également d'observer la distribution de chaque variable sur la diagonale.

```
sns.pairplot(df[['age', 'trestbps', 'chol', 'thalach']])
plt.show()
```

4.4 Analyse graphique : heatmap de corrélation

La heatmap de corrélation synthétise les coefficients de corrélation entre plusieurs variables quantitatives. Elle permet d'identifier rapidement les couples de variables les plus liés.

```
corr_matrix = df[['age', 'trestbps', 'chol', 'thalach']].corr()
plt.figure(figsize=(8, 6))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt='.2f', linewidths=.5)
plt.title('Heatmap de la matrice de corrélation')
plt.show()
```

4.5 Analyse numérique : corrélation

Le coefficient de corrélation de Pearson varie entre -1 et +1. Plus sa valeur absolue est élevée, plus la relation linéaire entre les deux variables est marquée.

```
correlation = df['age'].corr(df['trestbps'])
correlation
```

Valeur de r	Interprétation usuelle
0 à 0,19	Relation linéaire très faible ou quasi nulle.
0,20 à 0,39	Relation faible.
0,40 à 0,59	Relation modérée.
0,60 à 0,79	Relation forte.
0,80 à 1,00	Relation très forte.

Questions d'analyse :

- Le nuage de points suggère-t-il une relation croissante, décroissante ou peu marquée entre age et trestbps ?
- Quelle paire de variables semble la plus liée dans le pairplot et dans la heatmap ?
- La corrélation calculée entre age et trestbps confirme-t-elle l'impression visuelle donnée par le scatter plot ?
- Pourquoi une corrélation faible ne signifie-t-elle pas forcément qu'il n'existe aucune relation entre deux variables ?

5. Partie B – Analyse bivariée quali-quali

L'analyse quali-quali étudie la relation entre deux variables catégorielles. Dans ce TP, nous allons examiner le lien entre sex et cp, c'est-à-dire entre le sexe du patient et le type de douleur thoracique.

5.1 Préparation des variables qualitatives

Même si certaines variables sont codées par des nombres, elles représentent ici des catégories. Il est donc préférable de les convertir en chaînes de caractères ou en catégories avant la visualisation.

```
df[['sex', 'cp']] = df[['sex', 'cp']].astype(str)
```

5.2 Analyse graphique : diagramme en barres

```
sns.countplot(x='sex', hue='cp', data=df)
plt.title('Relation entre le sexe et le type de douleur thoracique')
plt.show()
```

5.3 Analyse graphique : barres empilées en proportions

Les proportions empilées permettent de comparer la structure des catégories à l'intérieur de chaque groupe. Elles sont utiles lorsque les effectifs des groupes sont différents.

```
proportions = df.groupby('sex')['cp'].value_counts(normalize=True).unstack()
proportions.plot(kind='bar', stacked=True)
plt.title('Relation entre le sexe et le type de douleur thoracique (en
pourcentages)')
plt.ylabel('Proportion')
plt.xlabel('Sexe')
plt.legend(title='Type de douleur thoracique')
plt.show()
```

5.4 Analyse graphique : heatmap du tableau de contingence

```
contingency_table = pd.crosstab(df['sex'], df['cp'])
sns.heatmap(contingency_table, annot=True, cmap='coolwarm')
plt.title('Heatmap : relation entre le sexe et le type de douleur thoracique')
plt.show()
```

5.5 Analyse numérique : tableau croisé simple et tableaux croisés normalisés

Le tableau croisé simple donne les effectifs. Les tableaux croisés normalisés permettent d'interpréter des proportions globales, par ligne ou par colonne.

```
pd.crosstab(df['sex'], df['cp'])

pd.crosstab(df['sex'], df['cp'], normalize=True)
pd.crosstab(df['sex'], df['cp'], normalize='index')
pd.crosstab(df['sex'], df['cp'], normalize='columns')
```

Remarque : `normalize=True` donne des proportions globales, `normalize='index'` donne des proportions par ligne, et `normalize='columns'` donne des proportions par colonne.

Questions d'analyse :

- Le type de douleur thoracique semble-t-il réparti de la même façon chez les hommes et chez les femmes ?
- Quel graphique vous paraît le plus facile à interpréter entre le countplot, les barres empilées et la heatmap ? Justifier.
- Pourquoi les tableaux normalisés sont-ils souvent plus utiles que les effectifs bruts pour comparer deux groupes de tailles différentes ?

6. Partie C – Analyse bivariable quanti-quali

L'analyse quanti-quali étudie la relation entre une variable quantitative et une variable qualitative. Nous allons ici comparer la distribution de l'âge selon le sexe du patient.

6.1 Analyse graphique : boxplot

```
sns.boxplot(x='sex', y='age', data=df)
plt.title("Relation entre le sexe et l'âge")
plt.show()
```

6.2 Version interactive facultative avec Plotly

Cette visualisation n'est pas obligatoire pour le rendu, mais elle permet d'explorer les données de manière interactive dans un notebook Jupyter.

```
import plotly.express as px

fig = px.box(df, x='sex', y='age',
             title="Relation entre le sexe et l'âge",
             labels={'sex': 'Sexe', 'age': 'Âge'})
fig.show()
```

6.3 Analyse numérique : statistiques descriptives par groupe

```
mean_age_by_sex = df.groupby('sex')['age'].mean()
mean_age_by_sex

age_stats_by_sex = df.groupby('sex')['age'].agg(
    mean_age='mean',
    median_age='median',
    std_age='std'
)
print(age_stats_by_sex)
```

Travail demandé :

- Comparer visuellement les médianes et les dispersions des âges selon le sexe à l'aide du boxplot.
- Calculer la moyenne, la médiane et l'écart-type de l'âge pour chaque catégorie de sexe.
- Dire si l'âge moyen semble similaire ou différent selon le sexe, en vous appuyant à la fois sur le graphique et sur les statistiques.

Questions d'analyse :

- Le boxplot met-il en évidence une différence nette entre les groupes ?
- Pourquoi est-il utile de regarder à la fois la médiane, la moyenne et l'écart-type ?
- Peut-on conclure à une causalité à partir de cette simple comparaison bivariable ? Pourquoi ?

7. Synthèse et travail à rendre

- Le notebook Python complété et exécuté avec les trois parties du TP.
- Un court compte rendu présentant, pour chaque type d'analyse bivariable, le graphique principal retenu et son interprétation.
- Une conclusion personnelle expliquant quelle relation vous a semblé la plus intéressante dans le jeu de données.

8. Extension facultative

- Remplacer le couple (age, trestbps) par un autre couple de variables quantitatives et comparer les résultats.
- Étudier la relation entre target et une variable qualitative de votre choix à l'aide d'un tableau croisé.
- Comparer une autre variable quantitative par groupe, par exemple chol selon cp ou thalach selon target.
- Proposer une interprétation métier des relations observées dans une perspective d'aide au diagnostic.

TP3 : Statistiques inférentielles pour le projet fil rouge

Support de travaux pratiques en Python – troisième étape du projet intégrateur

Contexte : Après l'analyse univariée et l'analyse bivariée, il faut maintenant passer à une logique de décision statistique. Dans ce TP, vous allez vérifier si les relations ou différences observées dans le jeu de données des maladies cardiaques sont statistiquement significatives, à l'aide de tests adaptés à la nature des variables étudiées.

Problématique : Comment déterminer, à partir d'un échantillon de patients, si une corrélation, une dépendance entre deux variables qualitatives ou une différence entre groupes peut être considérée comme suffisamment solide pour dépasser la simple observation descriptive ?

1. Objectifs pédagogiques

- Formuler correctement une hypothèse nulle H_0 et une hypothèse alternative H_1 .
- Choisir un test statistique en fonction de la nature des variables : quanti-quanti, quali-quali ou quanti-quali.
- Interpréter une p-value et prendre une décision statistique à un seuil de signification donné.
- Vérifier les conditions d'application d'un test, notamment la normalité et l'égalité des variances.
- Conclure de manière rigoureuse, sans confondre significativité statistique, taille d'effet et causalité.

2. Pré-requis et environnement de travail

- Avoir réalisé les TP1 et TP2 ou maîtriser les bases de pandas, seaborn, matplotlib, numpy et scipy.stats.
- Fichier de données attendu : **Base_Maladie_Cardiaque.csv**.
- Les analyses seront menées dans un notebook Python ou dans un environnement Jupyter/VS Code.
- Dans ce TP, on adopte par défaut un seuil de signification $\alpha = 0,05$.

3. Repères méthodologiques

En statistique inférentielle, on ne se contente plus de décrire les données. On cherche à décider si un résultat observé dans l'échantillon peut raisonnablement être généralisé à la population étudiée. Pour cela, on formule une hypothèse nulle H_0 , on calcule une statistique de test, puis on interprète la p-value.

Concept	Interprétation opérationnelle
Hypothèse nulle H_0	Situation de référence : absence de différence, d'effet ou d'association.
Hypothèse alternative H_1	Présence d'une différence, d'un effet ou d'une association.
p-value	Probabilité d'obtenir un résultat au moins aussi extrême que celui observé si H_0 était vraie.
Règle de décision	Si $p\text{-value} < 0,05$, on rejette généralement H_0 ; sinon, on ne dispose pas d'assez d'arguments pour la rejeter.
Prudence d'interprétation	Un résultat significatif ne prouve ni la causalité, ni l'importance clinique, ni la pertinence métier à lui seul.

3.1 Guide rapide de choix du test

Situation	Exemple	Test principal	Alternative
Deux variables quantitatives	age vs trestbps	Pearson	Spearman/Kendall si relation monotone ou conditions plus souples.
Deux variables qualitatives	sex vs target	Chi-deux	Cramér V ou Tschuprow pour quantifier l'intensité.
Une quantitative selon deux groupes	chol selon target	Student	Welch si variances différentes ; Mann-Whitney sinon.
Une quantitative selon plusieurs groupes	chol selon thal	ANOVA	Kruskal-Wallis si conditions non remplies.

Repère important : un test statistique vient confirmer ou nuancer une observation graphique, mais il ne remplace jamais l'analyse métier. Avant de conclure, il faut toujours vérifier le type de variable, la qualité des données, les hypothèses du test et le sens concret du résultat.

4. Mise en place du TP

4.1 Importation des bibliothèques et chargement du jeu de données

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from scipy import stats

df = pd.read_csv("data/Base_Maladie_Cardiaque.csv")
df.head()
```

Travail demandé :

- Exécuter le code précédent et vérifier que le fichier est correctement chargé.
- Afficher les types des variables avec `df.dtypes`.
- Identifier les variables qui seront utilisées dans ce TP : `age`, `trestbps`, `chol`, `sex`, `target`, `cp` et `thal`.
- Fixer explicitement le seuil $\alpha = 0,05$ dans votre notebook.

5. Partie A – Inférence sur deux variables quantitatives

Cette partie vise à tester si la relation observée entre deux variables quantitatives est compatible avec une vraie association statistique. Nous allons prendre comme exemple `age` et `trestbps`.

5.1 Corrélation de Pearson

Le test de corrélation de Pearson mesure la force d'une relation linéaire entre deux variables quantitatives. L'hypothèse nulle H_0 suppose l'absence de corrélation linéaire.

```
pearson_corr, pearson_pval = stats.pearsonr(df["age"], df["trestbps"])
pearson_corr, pearson_pval
```

5.2 Corrélations de Spearman et de Kendall

Ces deux coefficients sont utiles lorsque la relation n'est pas strictement linéaire ou lorsque l'on préfère raisonner sur les rangs plutôt que sur les valeurs brutes.

```
spearman_corr, spearman_pval = stats.spearmanr(df["age"], df["trestbps"])
kendall_corr, kendall_pval = stats.kendalltau(df["age"], df["trestbps"])

spearman_corr, spearman_pval
kendall_corr, kendall_pval
```

Questions d'analyse :

- La p-value associée à Pearson est-elle inférieure à 0,05 ? Quelle décision prenez-vous vis-à-vis de H_0 ?
- Le signe du coefficient indique-t-il une relation croissante ou décroissante ?
- Les résultats de Pearson, Spearman et Kendall racontent-ils la même histoire globale ?
- Pourquoi est-il utile de comparer plusieurs coefficients plutôt que de s'en tenir à un seul ?

6. Partie B – Inférence sur deux variables qualitatives

On étudie maintenant si deux variables catégorielles semblent indépendantes ou liées. Nous prendrons ici l'exemple de `sex` et `target`.

6.1 Tableau de contingence et test du Chi-deux

```
contingency_table = pd.crosstab(df["sex"], df["target"])
contingency_table
```

```
chi2, p_value, dof, expected = stats.chi2_contingency(contingency_table)
chi2, p_value, dof
```

6.2 Mesure de l'intensité de l'association

Le test du Chi-deux permet de décider s'il existe une dépendance statistique. Pour compléter l'analyse, on peut mesurer la force de l'association à l'aide du coefficient de Cramér ou de Tschuprow.

```
n = contingency_table.sum().sum()

cramer_v = np.sqrt(chi2 / (n * (min(contingency_table.shape) - 1)))
tschuprow_t = np.sqrt(
    chi2 / (n * np.sqrt((contingency_table.shape[0] - 1) * (contingency_table.shape[1] - 1)))
)

cramer_v, tschuprow_t
```

Questions d'analyse :

- Le test du Chi-deux conduit-il à rejeter l'hypothèse d'indépendance entre sex et target ?
- Pourquoi est-il utile d'ajouter Cramér V ou Tschuprow en plus de la p-value ?
- Une association statistiquement significative est-elle forcément forte ? Justifier à partir des coefficients calculés.
- Que représentent concrètement les effectifs attendus returned par chi2_contingency ?

7. Partie C – Vérification des hypothèses avant comparaison de groupes

Avant d'utiliser certains tests paramétriques comme Student ou ANOVA, il faut vérifier que les distributions sont raisonnablement compatibles avec les hypothèses du test. Cette étape ne doit pas être négligée.

7.1 Tests de normalité

```
x = df["trestbps"]
shapiro_test = stats.shapiro(x)
ks_test = stats.kstest(x, "norm", args=(x.mean(), x.std()))
```

Pour compléter l'analyse, on peut aussi exécuter Anderson-Darling, D'Agostino et Jarque-Bera.

```
anderson_test = stats.anderson(df["trestbps"], dist="norm")
dagostino_test = stats.normaltest(df["trestbps"])
jarque_bera_test = stats.jarque_bera(df["trestbps"])

anderson_test
dagostino_test
jarque_bera_test
```

7.2 Tests d'égalité des variances

Pour comparer plusieurs groupes, on peut aussi tester si leurs variances sont proches. Dans l'exemple suivant, on compare le cholestérol selon les catégories de thal.

```
chol_1 = df[df["thal"] == 1]["chol"]
chol_2 = df[df["thal"] == 2]["chol"]
chol_3 = df[df["thal"] == 3]["chol"]

levene_result = stats.levene(chol_1, chol_2, chol_3)
bartlett_result = stats.bartlett(chol_1, chol_2, chol_3)
fligner_result = stats.fligner(chol_1, chol_2, chol_3)

levene_result
bartlett_result
fligner_result
```

Questions d'analyse :

- Pourquoi ne faut-il pas appliquer automatiquement un test paramétrique sans vérifier au moins grossièrement ses hypothèses ?
- Les différents tests de normalité donnent-ils toujours exactement la même conclusion ?
- Entre Levene, Bartlett et Fligner, lequel vous paraît le plus robuste lorsque la normalité est discutable ?
- Comment utiliser les résultats de cette section pour orienter le choix entre Student et Welch, ou entre ANOVA et Kruskal-Wallis ?

8. Partie D – Comparaison d'une variable quantitative entre deux groupes

Nous allons maintenant comparer le taux de cholestérol chol entre les patients ayant une maladie cardiaque (target = 1) et les patients sains (target = 0).

8.1 Visualisation préparatoire

```
sns.boxplot(x="target", y="chol", data=df)
plt.title("Comparaison du cholestérol selon la présence d'une maladie cardiaque")
plt.show()
```

8.2 Test de Student et test de Welch

```
chol_malade = df[df["target"] == 1]["chol"]
chol_sain = df[df["target"] == 0]["chol"]

student_result = stats.ttest_ind(chol_malade, chol_sain)
welch_result = stats.ttest_ind(chol_malade, chol_sain, equal_var=False)

student_result
welch_result
```

8.3 Alternative non paramétrique : Mann-Whitney

Dans plusieurs notebooks, ce test est parfois présenté comme une alternative de type Wilcoxon pour deux groupes indépendants. En Python, la fonction utilisée ici est `mannwhitneyu`.

```
mannwhitney_result = stats.mannwhitneyu(chol_malade, chol_sain)
mannwhitney_result
```

Travail demandé :

- Comparer visuellement les deux groupes à l'aide du boxplot.
- Exécuter Student, Welch et Mann-Whitney, puis comparer les p-values obtenues.
- Justifier le test que vous retenir finalement en fonction des hypothèses vérifiées à la section précédente.
- Rédiger une conclusion statistique claire en une ou deux phrases.

9. Partie E – Comparaison d'une variable quantitative entre plusieurs groupes

On cherche maintenant à savoir si le niveau de cholestérol diffère selon les catégories de thal.

9.1 ANOVA

```
anova_result = stats.f_oneway(chol_1, chol_2, chol_3)
anova_result
```

9.2 Alternative non paramétrique : Kruskal-Wallis

```
kruskal_result = stats.kruskal(chol_1, chol_2, chol_3)
kruskal_result
```

Questions d'analyse :

- L'ANOVA permet-elle de rejeter l'hypothèse d'égalité des moyennes entre les groupes ?
- Le test de Kruskal-Wallis mène-t-il à une conclusion cohérente avec l'ANOVA ?
- Dans quel cas préféreriez-vous Kruskal-Wallis à ANOVA ?
- Que manque-t-il encore pour identifier précisément quels groupes diffèrent entre eux après une ANOVA significative ?

10. Synthèse et travail à rendre

- Le notebook Python complété, exécuté et bien commenté.
- Un compte rendu synthétique de 2 à 3 pages présentant pour chaque partie : les hypothèses, le test choisi, la p-value et la conclusion.
- Une comparaison argumentée entre au moins un test paramétrique et un test non paramétrique.
- Une conclusion finale rappelant qu'un résultat statistiquement significatif ne suffit pas, à lui seul, pour conclure à une causalité.

11. Extension facultative

- Tester une autre corrélation entre deux variables quantitatives, par exemple age et chol ou thalach et oldpeak.
- Étudier l'association entre target et cp ou entre target et thal à l'aide d'un test du Chi-deux.
- Comparer une autre variable quantitative selon deux groupes, par exemple thalach selon sex.
- Construire une petite fonction Python qui propose automatiquement un test à partir du type des variables étudiées.